Rapport

Juliette SIEBERING, Adeline VERCOUTRE, Antoine NERET, Karl MEHANNA

20 avril 2026

```
library(ggplot2)
library(dplyr)

# Le fichier étant trop lourd pour GitHub, il n'est pas dans le dc
jeux <- read.csv('../../games_march2025_cleaned.csv')
```

Introduction

Notre jeu de données regroupe une grande partie des jeux publiés par Steam, avec de nombreuses informations comme le prix, le système d'exploitation, la date de publication, etc... (voir tableau ci-dessous). Il provient du site Kaggle, nous avons choisi ce jeu en particulier pour sa richesse (89618 observations et 47 variables) et pour sa récence (les données datent de mars 2025). Étant tous des joueurs dans le groupe, cela nous paraît intéressant de voir les données concernant nos jeux préférés.

Question 1

L'une des premières observations issues de notre jeu de données concerne les colonnes *Windows*, *Linux* et *Mac*, qui correspondent aux trois systèmes d'exploitation les plus répandus dans le monde.

Cela soulève naturellement la question suivante :

Parmi ces trois systèmes d'exploitation, lequel prend en charge le plus grand nombre de jeux ?

```
# On transforme les chaînes de caractère "TRUE" et "FALSE" en bool
jeux <- jeux %>%
  mutate(
    windows = as.logical(windows),
    mac     = as.logical(mac),
    linux   = as.logical(linux)
  )

# On crée un tableau avec, pour chaque système d'exploitation, la
nb_jeux_sys_ex <- data.frame(
  sys_ex = c("Windows", "Mac", "Linux"),
  nb = c(
    sum(jeux$windows),
    sum(jeux$mac),
    sum(jeux$linux)
  )
)

# On crée la visualisation correspondante : un bar chart avec la s
repartition_systemes <- ggplot(data = nb_jeux_sys_ex, mapping = ae
  geom_col() +
  geom_text(aes(label = nb), vjust = -0.5) +
  labs(title = "Nombre de jeux supportés par les différents systèm
       x = "Système d'exploitation", y = "Nombre de jeux") +
  theme(legend.position = "none") # La légende n'est pas nécessair
repartition_systemes
```

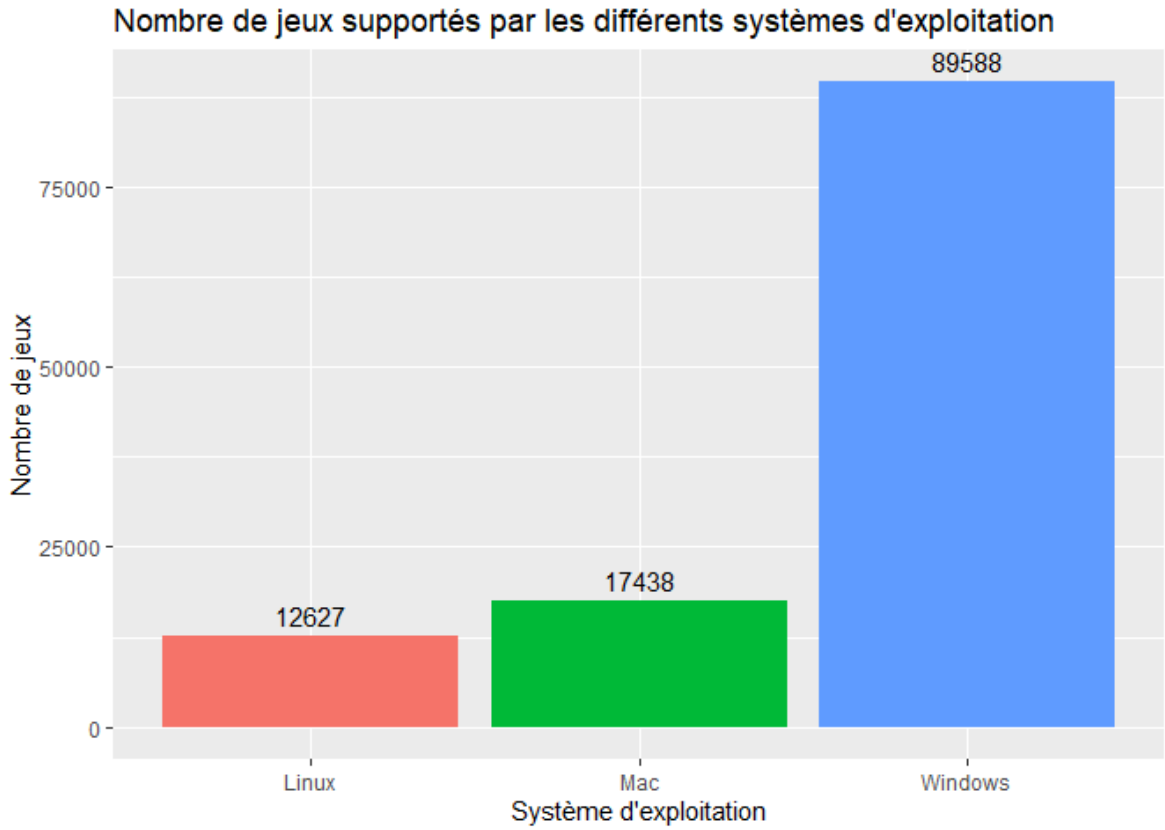

L'analyse montre clairement que Windows domine largement les autres. En effet, il propose environ cinq fois plus de jeux que Mac et sept fois plus que Linux.

Question 2

La deuxième observation de notre jeu de données concerne les colonnes *average_playtime_forever* et *price*, qui correspondent au temps de jeu moyen des joueurs et au prix des jeux.

La question soulevée par ces colonnes est la suivante :

Les joueurs passent-ils plus de temps sur les jeux payant ou sur les jeux gratuits ?

```
# On filtre les jeux pour n'avoir que les gratuits
jeux_gratuits <- filter(jeux,price == 0.00)

# On calcule la moyenne des heures de jeu
jeux_gratuits <- jeux_gratuits %>%

# On fait la moyenne du temps de jeu moyen pour les les jeux gratu
transmute(average_playtime_forever=(mean(average_playtime_forever)
```

```
# La fonction distinct nous assure d'avoir une seule valeur
distinct()

# On filtre les jeux pour n'avoir que les payants
jeux_payants <- filter(jeux,price > "0.0")

# On calcule la moyenne des heures de jeu
jeux_payants <- jeux_payants %>%

# Comme pour les jeux gratuits, on fais la moyenne du temps de jeu
transmute(average_playtime_forever=(mean(average_playtime_forever)

# On fusionne les moyennes en un seul dataframe
tps_jeu_moyen <- rbind(jeux_gratuits,jeux_payants)

# On fait la visualisation correspondante, c'est-à-dire un bar cha
ggplot(tps_jeu_moyen, aes(x = c("Jeux gratuits", "Jeux payants"),
  geom_bar(stat='identity') +
  ggtitle("Nombre moyen d'heures de jeu en fonction de la gratuité
  labs(x = "Gratuité des jeux", y = "Nombre moyen d'heures de jeu'
  theme(legend.position = "none") + # Il n'y a pas besoin de léger
  scale_fill_manual(values = c("#55E250","#1F96E0")) # On met de l
```

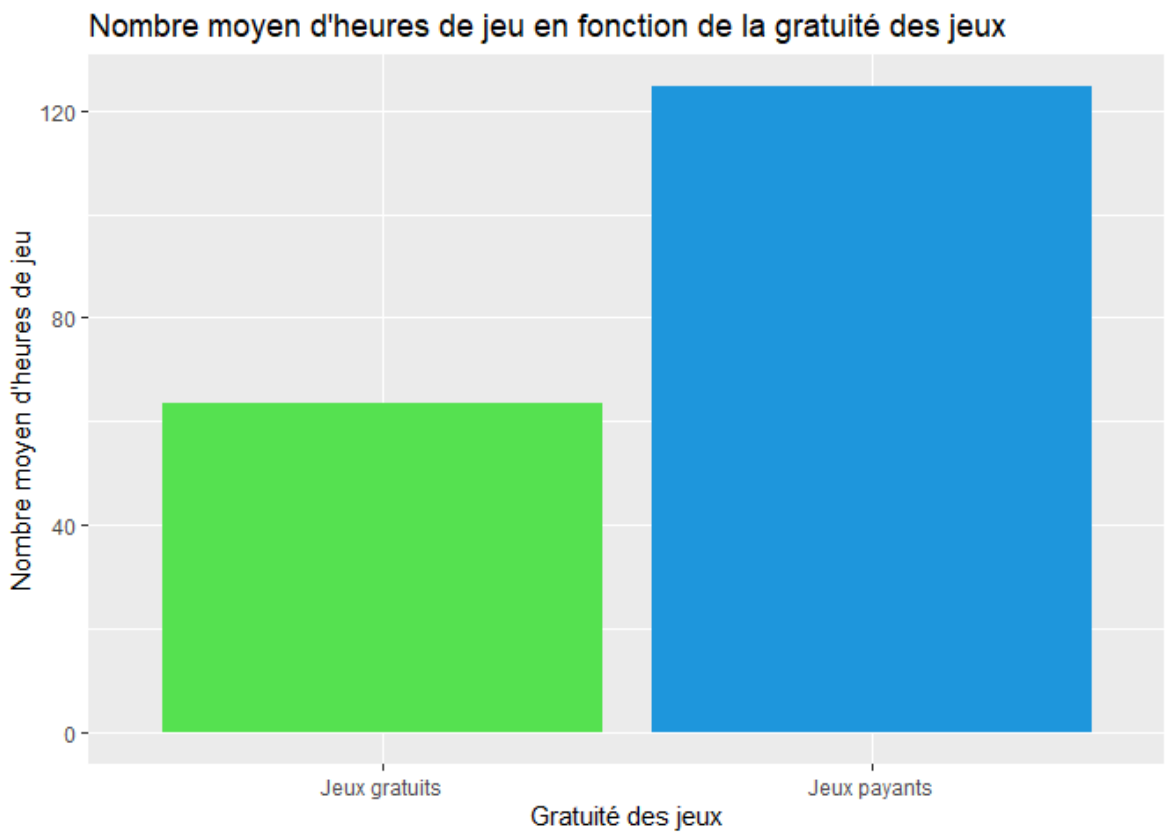

Sur le graphe ci-dessus, on peut voir qu'en moyenne les joueurs jouent deux fois plus longtemps aux jeux payants qu'aux jeux gratuits. Cette différence peut s'expliquer par la différence de coût pour faire l'acquisition des jeux constituant ces différentes catégories.

Question 3

Une autre observation intéressante de notre jeu de données concerne les colonnes *price* et *estimated_owners*, qui correspondent respectivement au prix d'un jeu et à son nombre estimé de propriétaires.

Cela soulève la question suivante :

Est-ce que le prix influence les ventes ?

```
# On ne garde que les jeux qui ont une estimation d'owners
data <- jeux[jeux$estimated_owners != "0 - 0", ]

# On crée une nouvelle variable catégorielle à partir de la variab
owner_levels <- unique(data$estimated_owners)
owner_order <- owner_levels[order(sapply(strsplit(owner_levels, "
data$owners_cat <- factor(data$estimated_owners, levels = owner_or

# On crée une fonction pour formater les catégories d'estimation d
format_millions <- function(x) {
  sapply(strsplit(x, " - "), function(parts) {
    parts <- as.numeric(parts) # On convertit les parties en numér
    fmt <- function(n) {
      if (n >= 1e6) paste0(n/1e6, "M") # Si le nombre est supérieu
      else if (n >= 1e3) paste0(n/1e3, "K") # Si le nombre est sup
      else n # Sinon, on laisse le nombre tel quel
    }
    paste0(fmt(parts[1]), " - ", fmt(parts[2])) # On reformate les
  })
}

# On calcule le prix moyen et le pourcentage de jeux gratuits pour
means <- aggregate(price ~ owners_cat, data = data, FUN = mean)
pct   <- aggregate(price ~ owners_cat, data = data, FUN = function
means$pct_gratuit <- pct$price
means$label <- factor(format_millions(as.character(means$owners_ca
means$x <- as.numeric(means$label)
```

```r
# On ajuste une courbe de tendance pour le prix moyen en fonction
scale_factor <- max(means$price) / 100
means$smooth <- pmax(predict(loess(price ~ x, data = means)), 0)

# Visualisation combinée du prix moyen et du pourcentage de jeux g
ggplot(means, aes(x = x)) +
  geom_bar(aes(y = pct_gratuit * scale_factor), stat = "identity",
           fill = "#e15759", alpha = 0.35, width = 0.7) + # Barres
  geom_area(aes(y = smooth), fill = "#4e79a7", alpha = 0.1) + # Zo
  geom_line(aes(y = smooth), color = "#4e79a7", linewidth = 1.4) +
  scale_x_continuous(breaks = means$x, labels = means$label) +
  scale_y_continuous(
    name = "Prix moyen ($)",
    sec.axis = sec_axis(~ . / scale_factor, name = "% de jeux grat
                        labels = function(x) paste0(x, "%")) # Axe
  ) +

  # On ajoute un titre et un sous-titre pour expliquer les élément
  labs(
    title = "Est-ce que le prix influence les ventes ?",
    subtitle = "Ligne bleue = prix moyen | Barres rouges = % de je
    x = "Nombre de propriétaires estimés"
  ) +
  theme_minimal(base_size = 13) +
  theme(
    plot.title = element_text(face = "bold", size = 15),
    plot.subtitle = element_text(color = "grey40", size = 10),
    axis.text.x = element_text(angle = 45, hjust = 1),
    axis.title.y.left = element_text(color = "#4e79a7", face = "bo
    axis.title.y.right = element_text(color = "#e15759", face = "b
    panel.grid.minor = element_blank()
  )
```

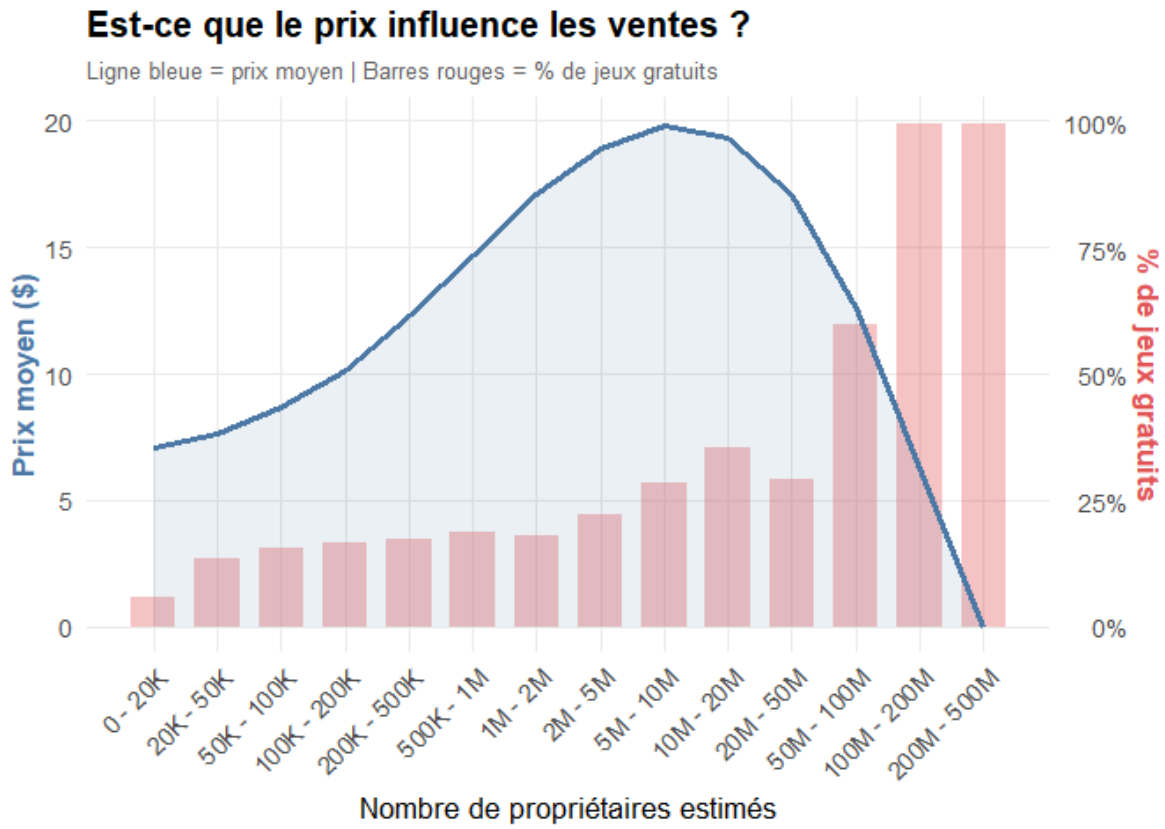

Le prix moyen des jeux augmente avec le nombre de propriétaires jusqu'à un certain seuil, puis diminue fortement pour les catégories les plus populaires. On remarque également que la part de jeux gratuits est plus élevée dans les catégories les plus populaires.

On peut donc considérer que le prix influence les ventes, mais les jeux les plus populaires sont souvent gratuits ou peu chers, ce qui montre que l'accessibilité joue un rôle clé lors de l'achat d'un jeu.

Question 4

En parcourant les différentes variables du jeu de données, la mise en relation des colonnes *price* désignant le prix d'un jeu et *pct_pos_total* correspondant à la note attribuée au jeu semblait intéressante. En effet, on s'attendrait à ce que plus on mette d'argent dans un jeu, meilleur il soit.

D'où la question suivante :

Est-ce que le prix influence la qualité ?

Tout d'abord, pour répondre à la question, nous avons exploré le jeu de données pour voir s'il était cohérent de représenter dans son entièreté

un graphique mettant en relation prix et avis positifs des jeux.

```
# On ne conserve que les jeux qui ont une note
reviews_prix <- jeux %>% filter(pct_pos_total > 0)

# Histogramme de la répartition du nombre de jeux en fonction du p
ggplot(reviews_prix, mapping = aes(x = price)) +
  geom_histogram() +
  labs(title = "Répartition du nombre de jeux en fonction du prix"
```

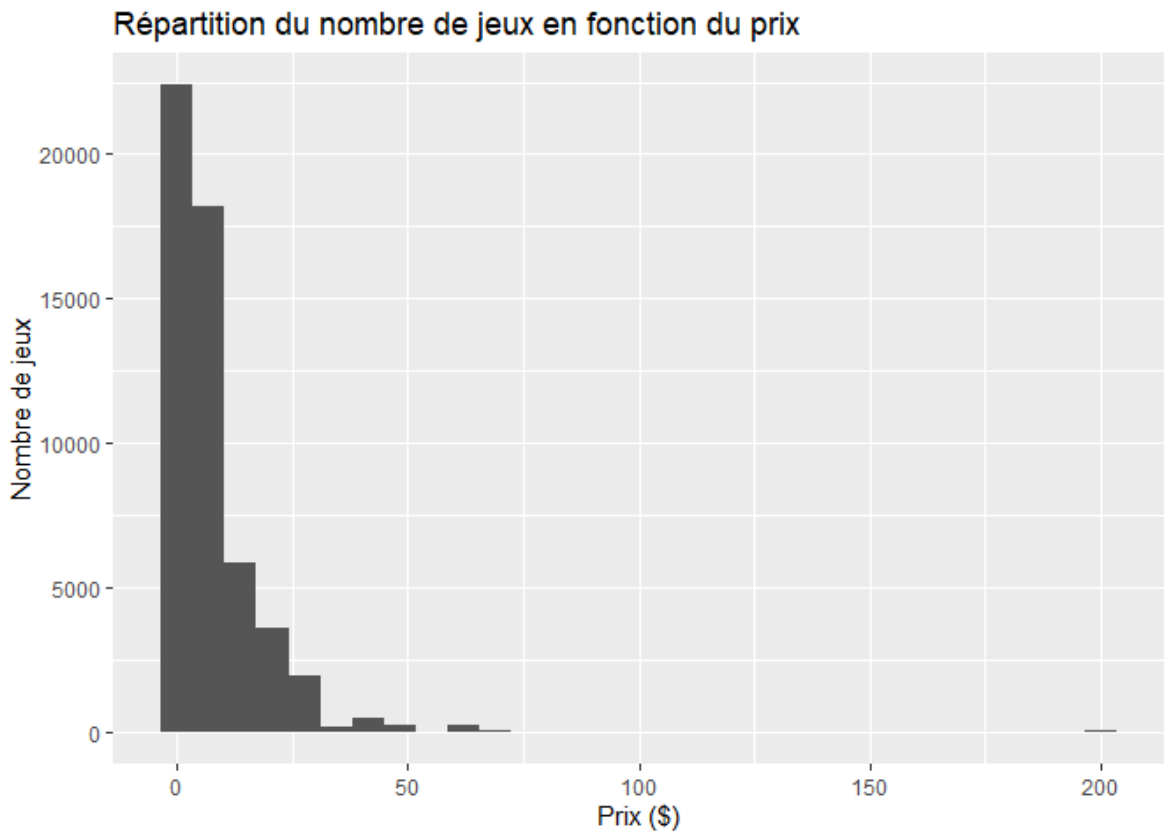

Après exploration des données, on se rend compte qu'il y a très peu de jeux dont le prix est supérieur à 70 dollars, ainsi on décide d'écarter ces jeux pour avoir une meilleure visibilité de la tranche la plus représentée (jeux allant de la gratuité à 70 dollars).

```
# On ne garde que les jeux possédant une note et dont le prix est
reviews_prix <- jeux %>% filter(pct_pos_total > 0, price < 70)

# Graphique présentant la distribution des notes données aux jeux

ggplot(reviews_prix, mapping = aes(x = cut(price, breaks = 14), y
  geom_boxplot() +
```

```
  labs(title = "Distribution des notes données aux jeux par tranch
  theme(axis.text.x = element_text(angle = 45, hjust = 1)) # Les t
```

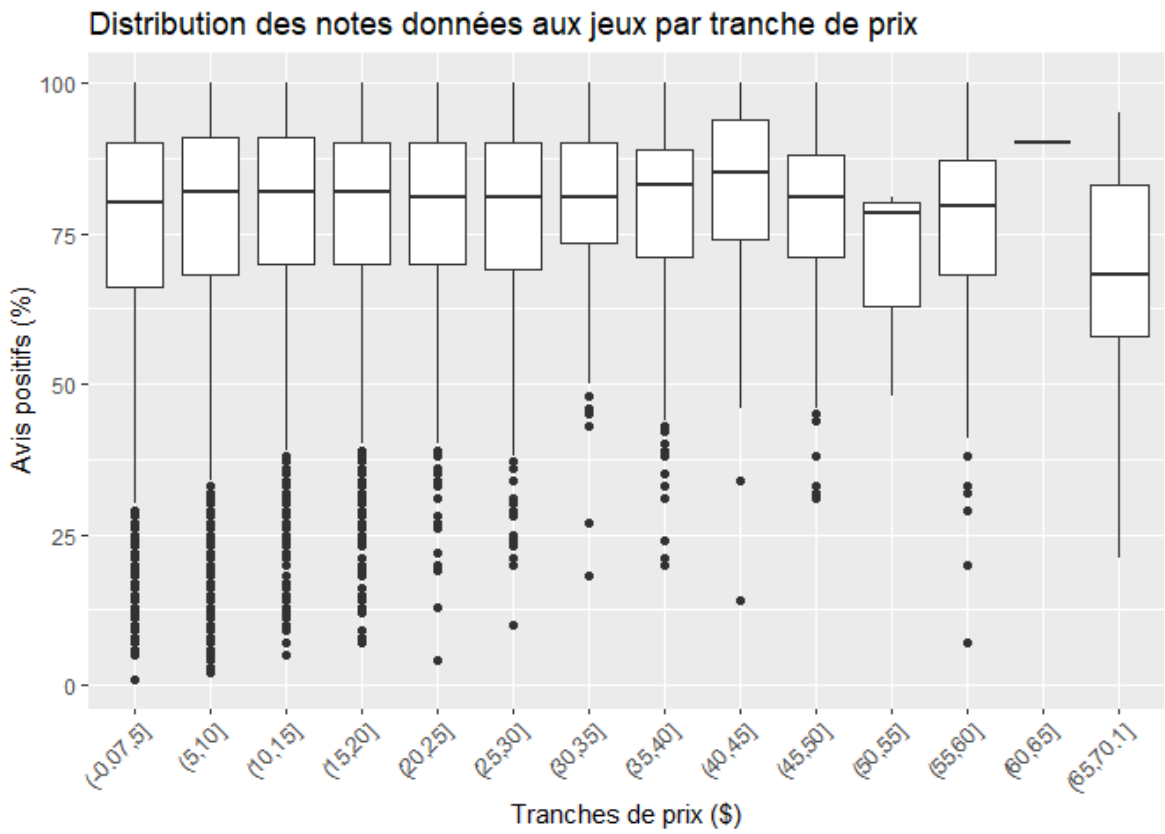

D'après le graphique pour chaque tranche de prix, le pourcentage d'avis positif reste à priori le même. Ainsi, on ne peut pas vraiment dire que le prix influence la qualité d'un jeu. Cependant, est-il réellement intéressant de voir si le prix influence la qualité sans même savoir le nombre de notes qui ont été attribuées dans chaque tranche ?

```
# Mêmes données que précédemment
reviews_prix <- jeux %>% filter(pct_pos_total > 0, price < 70)

# Graphique présentant la distribution du nombre de reviews des je

ggplot(reviews_prix, mapping = aes(x = cut(price, breaks = 14), y
  geom_boxplot() +
  coord_cartesian(ylim = c(0, 50000)) +
  labs(title = "Distribution du nombre de reviews des jeux par tra
  theme(axis.text.x = element_text(angle = 45, hjust = 1)) # Les t
```

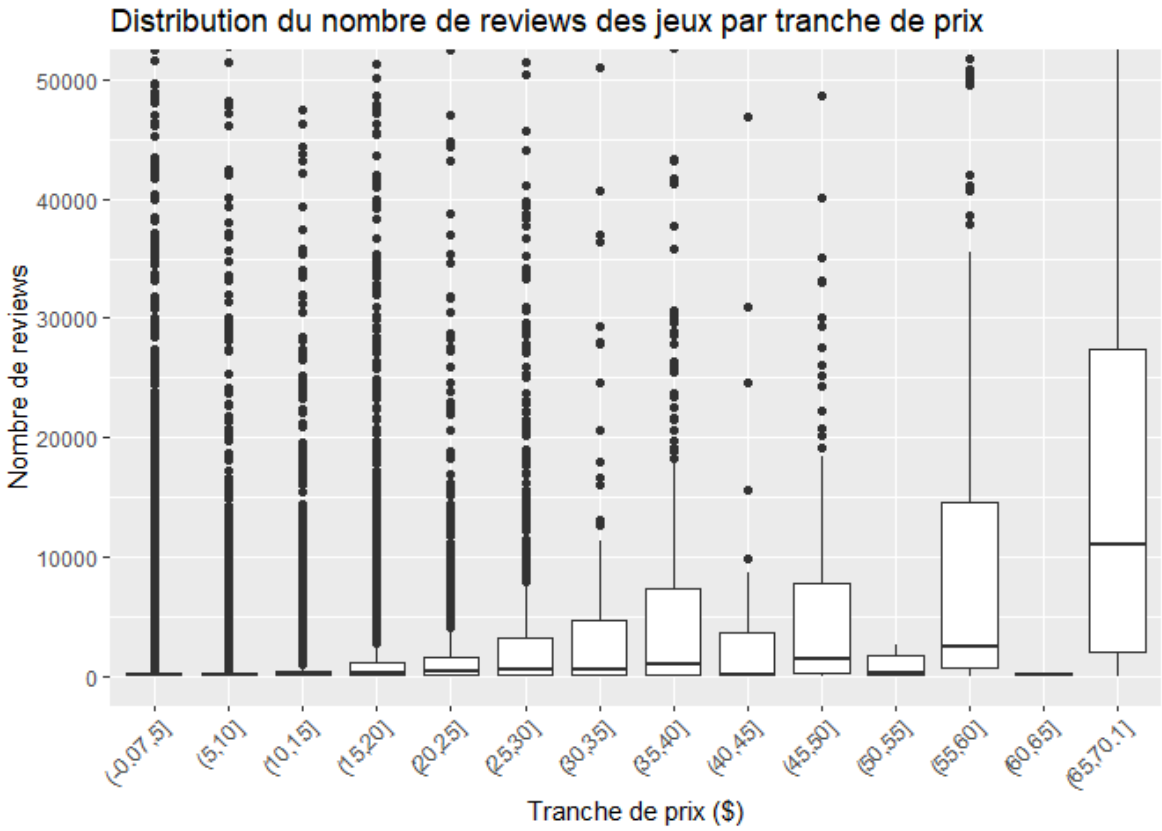

On constate que plus le jeu est cher, plus on a d'avis et donc de notes à propos de celui-ci. Ainsi on peut imaginer que les notes qui sont attribuées à un jeu à prix élevé sont plus fiables (car plus nombreuses) que pour un jeu peu coûteux voire gratuit.